

Pipeline de Datos: Fichajes y Coeficientes UEFA

Cómo funciona el proyecto — arquitectura, flujo de datos y los cambios de esta versión.

Contenido

1. Qué cambió en esta versión
2. Qué problema resuelve el proyecto
3. Arquitectura y estructura del repositorio
4. Qué se guarda exactamente en cada capa
5. Las tres fuentes de datos
6. El DAG paso a paso, con los conceptos de Airflow
7. Diagrama del flujo completo
8. Cómo se cruzan los nombres de club (tokenización)
9. Cómo correrlo: modo prueba y prueba local
10. Validación de calidad de datos
11. Unidad de análisis y diccionario de columnas
12. Lo que hay que saber explicar (defensa oral)
13. Glosario rápido de Airflow

Repositorio: **airflow-proyecto** · DAG: **pipeline_fichajes**

Apache Airflow 3.3 sobre Astro Runtime

Contenido

1. Qué cambió en esta versión
 2. Qué problema resuelve el proyecto
 3. Arquitectura y estructura del repositorio
 4. Qué se guarda exactamente en cada capa
 5. Las tres fuentes de datos
 6. El DAG paso a paso, con los conceptos de Airflow
 7. Diagrama del flujo completo
 8. Cómo se cruzan los nombres de club (tokenización)
 9. Cómo correrlo: modo prueba y prueba local
 10. Validación de calidad de datos
 11. Unidad de análisis y diccionario de columnas
 12. Lo que hay que saber explicar (defensa oral)
 13. Glosario rápido de Airflow
-

1. Qué cambió en esta versión

Trece cambios de fondo. Tres salieron de las correcciones del profesor, siete aparecieron al revisar los datos y el código, y los tres últimos salieron de preparar la Entrega 2 sobre este mismo dataset.

#	Qué cambió	Antes	Ahora
1	El DAG se dispara solo	<code>schedule=None</code> : había que apretar el botón	<code>schedule="@ 6 * * *"</code> , y decide si trabajar comparando una huella de las fuentes
2	Se guarda el bronce de Transfermarkt	el HTML se parseaba en memoria y se tiraba	se guarda el HTML crudo comprimido, particionado por club y temporada
3	Clubes de origen enriquecidos	sólo el nombre del club	país, liga, ranking y coeficiente UEFA, si es europeo, si es top 20/50, y tres columnas derivadas del par origen-destino
4	El top 20 sale de UEFA	los primeros 20 del ranking de Transfermarkt	coeficiente de clubes de UEFA de las últimas diez temporadas
5	Qué filas entran al dataset	sólo los fichajes con importe publicado	todos los fichajes; se saca únicamente lo que no es un fichaje (sección 11.2)
6	Los filiales no heredan el ranking	"Chelsea FC U21" cruzaba contra Chelsea y quedaba como club top 10	se detectan y se marcan aparte (sección 11.3)
7	La clave primaria	<code>(jugador_tm_id, temporada_fichaje)</code> , que perdía traspasos	<code>operacion_id</code> , el id del traspaso en Transfermarkt
8	Las métricas del resumen ya no se pierden	si FotMob no mandaba el detalle, se descartaba también el resumen	se conserva lo que haya llegado (sección 12.3)
9	Menos columnas, y ninguna repetida	seis columnas que repetían lo que ya decía otra	se sacaron; el linaje pasó de tres columnas a una (sección 11.4)
10	Una sola corrida a la vez	dos corridas simultáneas consolidaban el bronce de la otra a medio escribir	<code>max_active_runs=1</code> (sección 9.3)

#	Qué cambió	Antes	Ahora
11	Cuatro temporadas en vez de tres	<code>temporadas_hacia_atras=3</code>	4. Es la única palanca que agrega clase positiva: 825 positivos en vez de 611 (sección 6.12)
12	La plata no arma features	se había puesto un puntaje de rendimiento normalizado por posición	se sacó: depende de qué filas entren al análisis, así que vive en el notebook (sección 4.6)
13	Un parámetro para restringir la población	no existía	<code>exigir_estadisticas</code> , apagado por defecto (sección 6.12)

Además hubo seis correcciones de datos que aparecieron en el camino y están explicadas en la sección 12.2.

Por qué cuatro temporadas y no más clubes

La pregunta obvia era subir el tope del ranking de destino para tener más datos. No funciona, y conviene entender por qué: la columna objetivo es `club_destino_ranking_uefa <= 20`, así que **sólo veinte clubes en el mundo pueden producir un positivo**. Medido sobre el bronce, cada banda del ranking aporta esto:

banda de ranking	clubes	filas	positivos
1–20	20	825	825
21–50	28	1.564	0
51–100	49	2.480	0
101–150	45	2.725	0
151–200	46	2.758	0

Ir de 200 a 400 clubes agregaría unas 11.000 filas y **ningún positivo**: la tasa caería del 8,0% a ~4,7% y el desbalance empeoraría. Una temporada más, en cambio, agrega filas de las dos clases en la misma proporción.

Importante para el equipo

La **capa bronce vieja del Drive ya no sirve**, y no se puede convertir: no contiene el HTML de Transfermarkt, así que de ahí no se puede sacar ni la liga del club de origen, ni el id del club, ni la edad real al fichaje. Hay que regenerarla corriendo el DAG.

2. Qué problema resuelve el proyecto

El objetivo es construir un dataset de fichajes donde **cada fila combine dos cosas que viven en fuentes distintas**:

- **el traspaso**: quién fue transferido, de qué club a qué club, por cuánto dinero, y qué clase de club es cada uno;
- **el rendimiento previo**: cómo venía jugando ese jugador en la temporada **anterior** al traspaso (minutos, goles, xG, precisión de pases...).

Con eso se puede estudiar la pregunta del proyecto: qué distingue a un fichaje que termina en un club de élite de uno que no. La variable objetivo es `es_destino_top_20`.

Construirlo a mano no escala —son miles de fichajes en varias temporadas— así que se arma con un pipeline de extracción y transformación orquestado con **Apache Airflow**.

3. Arquitectura y estructura del repositorio

El proyecto corre sobre **Docker**, usando **Astro CLI** (la herramienta de Astronomer que levanta un entorno de Airflow completo con un solo comando: `astro dev start`). Eso crea varios contenedores: el `api-server` (la interfaz en `localhost:8080`), el `scheduler` (el proceso que decide cuándo correr cada tarea), el `dag-processor` (el que lee la carpeta `dags/`) y una base Postgres con la metadata de Airflow.

```

airflow-proyecto/
├── dags/
│   └── dag_fichajes.py      define el DAG: 11 tareas y sus dependencias
├── include/
│   ├── fichajes/          la lógica pesada, separada en módulos
│   │   ├── bronze.py      rutas y escritura de la capa cruda
│   │   ├── uefa.py        cliente de la API de coeficientes de UEFA
│   │   ├── transfermarkt.py descarga y parseo del HTML
│   │   ├── fotmob.py       cliente de la API de estadísticas
│   │   ├── clubes.py      cruce de nombres UEFA con Transfermarkt
│   │   ├── plata.py       bronce al dataset consolidado
│   │   ├── esquema.py     columnas, tipos y umbrales de validación
│   │   └── prueba_local.py corrida chica sin Airflow
│   ├── bronze/            capa cruda (no se versiona en git)
│   ├── silver/            dataset consolidado (no se versiona)
│   ├── output/            el entregable fechado de cada corrida
│   └── frozen/            respaldo congelado
└── docs/

```

Por qué la lógica no vive en dags/

El `dag-processor` vuelve a parsear la carpeta `dags/` cada pocos segundos, así que ahí va sólo la definición del flujo. Todo lo que sea trabajo de verdad vive en `include/` y se importa. Es también la razón de que un DAG nuevo tarde unos segundos en aparecer en la interfaz: no está roto, está esperando a que el procesador vuelva a escanear la carpeta.

3.1 Qué hace cada módulo

Módulo	Responsabilidad	Detalle
<code>bronze.py</code>	dónde y cómo se guarda el crudo	arma las rutas particionadas, escribe y lee <code>.gz</code> , y define la regla de qué es inmutable
<code>uefa.py</code>	cliente de la API de coeficientes	pagina la API, devuelve los 554 clubes y las 55 asociaciones, y aplanar el JSON a filas
<code>transfermarkt.py</code>	descarga y parseo del HTML	funciones <code>bajar_*</code> (tocan la red, devuelven HTML) separadas de <code>parsear_*</code> (no tocan la red)
<code>fotmob.py</code>	cliente de estadísticas	busca al jugador, desambigua entre homónimos y arma el registro de la temporada
<code>clubes.py</code>	el cruce por nombre	normaliza, bloquea por país y compara; también responde "¿este país es europeo?"
<code>plata.py</code>	bronze a dataset	lee las tres capas crudas, aplanar, limpiar, enriquecer, deduplicar y escribir el CSV
<code>esquema.py</code>	el contrato del dataset	la lista de columnas y los umbrales en un solo lugar

La separación entre `bajar_*` y `parsear_*` en `transfermarkt.py` no es cosmética: es lo que permite que la capa plata se pueda correr cien veces mientras se depura el parseo, **sin pedirle nada a Transfermarkt**.

4. Qué se guarda exactamente en cada capa

El proyecto sigue la **arquitectura Medallion**, que organiza los datos en capas de calidad creciente.

4.1 Capa bronce — include/bronze/

Los datos **tal como los devolvió la fuente**, sin interpretar. Todo comprimido con gzip, y con la partición en la **ruta** y no en el nombre del archivo — es el mismo particionado que usa cualquier data lake sobre S3, con carpetas en lugar de prefijos de bucket.

Son cuatro tipos de archivo:

Ruta	Qué contiene	Cuántos hay
<code>uefa/actualizacion=<fecha>/clubes_diez_temporadas.json.gz</code>	la respuesta JSON completa de la API de UEFA: 554 clubes con su posición, coeficiente, país, id y las cuatro formas de su nombre	uno por cada actualización del ranking
<code>uefa/actualizacion=<fecha>/asociaciones.json.gz</code>	las 55 asociaciones miembro de UEFA con su posición y coeficiente de país	uno por actualización
<code>transfermarkt/ranking/actualizacion=<fecha>/pagina_NN.html.gz</code>	el HTML del ranking de clubes de Transfermarkt, página por página. De acá salen los ids y slugs , que son lo único que arma la URL de fichajes	unas 45 páginas por actualización
<code>transfermarkt/altas/club=<id>/temporada=<año>/altas.html.gz</code>	el HTML de la página de fichajes de un club en una temporada . Es la fuente del traspaso completo	uno por club y temporada
<code>fotmob/temporada=<año-año>/jugador_<id>.json.gz</code>	las estadísticas de un jugador en una temporada : biografía y métricas por torneo	uno por jugador y temporada

Ejemplo real de cómo queda:

```
include/bronze/
uefa/actualizacion=2026-09-17/clubes_diez_temporadas.json.gz
uefa/actualizacion=2026-09-17/asociaciones.json.gz
transfermarkt/ranking/actualizacion=2026-09-17/pagina_00.html.gz
transfermarkt/ranking/actualizacion=2026-09-17/pagina_01.html.gz
transfermarkt/altas/club=27/temporada=2026/altas.html.gz
transfermarkt/altas/club=27/temporada=2025/altas.html.gz
transfermarkt/altas/club=418/temporada=2026/altas.html.gz
fotmob/temporada=2025-2026/jugador_860914.json.gz
fotmob/temporada=2025-2026/jugador_776890.json.gz
```

La regla del bronce es append-only: lo que ya está en disco no se vuelve a pedir. De ahí salen las dos propiedades que lo justifican:

1. **La fuente se toca una vez por dato, no una vez por corrida.** La segunda corrida sobre el mismo material no genera ni una request.
2. **Un bug en el parseo no obliga a volver a la fuente.** Si mañana descubrimos que estábamos leyendo mal la columna del importe, se corrige la capa plata y se reprocesa lo que ya está en disco. Sin bronce, ese arreglo significa scrapear todo de nuevo — y si el sitio cambió en el medio, los datos viejos no se recuperan nunca más.

Hay **una sola excepción deliberada** a la regla, explicada en la sección 6.6: la página de la temporada en curso se vuelve a pedir, porque el mercado sigue abierto.

4.2 Qué NO está en el bronce de FotMob

Vale la pena aclararlo porque cambió respecto de la versión anterior. El archivo de FotMob guarda **sólo el rendimiento del jugador**: nada del fichaje.

antes: bronce_lionel_messi_2023-2024.json
(mezclaba club destino, coste, es_top_20 y métricas)

ahora: fotmob/temporada=2023-2024/jugador_123456.json.gz
(sólo biografía y métricas por torneo)

Los datos del traspaso viven en el bronce de Transfermarkt, que es de donde salen. El beneficio concreto: si el mismo jugador aparece en dos fichajes distintos, sus estadísticas de una temporada se piden **una sola vez**.

Contenido de un archivo de FotMob:

```
{
  "jugador_fotmob_id": "860914",
  "jugador_tm_id": "480692",
  "nombre_tm": "Luis Díaz",
  "temporada_stats": "2024/2025",
  "match_metodo": "club_destino",
  "nombre_fotmob": "Luis Díaz",
  "club_actual_fotmob": "Bayern München",
  "candidatos": 3,
  "biografia": {
    "altura_cm": 178, "pais_fotmob": "Colombia",
    "pie": "Left", "edad_hoy": 28,
    "posicion_fotmob": "Left Winger"
  },
  "torneos": [
    { "nombre": "Premier League", "torneo_id": 47,
      "metricas": { "Goals": 13.0, "Minutes": 2695.0, "Rating": 7.21, ... } },
    { "nombre": "Champions League", "torneo_id": 42,
      "metricas": { "Goals": 3.0, "Minutes": 612.0, ... } }
  ]
}
```

4.3 Capa plata — include/silver/

Los datos **limpios, tipados y consolidados**. Tres archivos:

Archivo	Qué es	Filas
dataset_fichajes_silver.csv	el dataset: una fila por fichaje, con el enriquecimiento de los dos clubes y las métricas del jugador	una por fichaje
dim_clubes.csv	la dimensión de clubes : los clubes que se van a procesar, con id de Transfermarkt, slug, nombre, país, posición y coeficiente de UEFA, y con qué método cruzó	una por club dentro del tope
dim_clubes_sin_cruce.csv	los clubes de Transfermarkt que no se pudieron cruzar contra UEFA, con el motivo	una por club sin cruce, de todo el catálogo

El tercero es tan importante como los otros dos: es lo que nos permite decir en la defensa cuántos clubes quedaron afuera y por qué, en vez de responder "no sé".

Los dos archivos no cubren el mismo universo

[dim_clubes.csv](#) trae sólo los clubes **dentro del tope** que se pidió en la corrida (188 con [tope_ranking_uefa=200](#)), mientras que [dim_clubes_sin_cruce.csv](#) trae los que no cruzaron en **todo** el catálogo de Transfermarkt, tope incluido o no.

Así que dividir uno por la suma de los dos **no da la cobertura del cruce**: mezcla un numerador recortado con un denominador que no lo está. La cobertura real está medida en la sección 8.5, sobre el catálogo completo.

4.4 Capa de salida — `include/output/`

Un CSV fechado por corrida: `fichajes_2026-09-17.csv`. Es una copia del dataset de plata con la fecha de la corrida en el nombre, y es **el entregable**.

Que el nombre lleve la fecha y no un número correlativo es lo que hace la tarea **idempotente**: correrla dos veces el mismo día sobrescribe el archivo, no deja dos. Si numerara, cada reintento agregaría uno nuevo y el conteo final dependería de cuántas veces falló.

4.5 Respaldo — `include/frozen/`

Dos archivos, y sólo uno se versiona:

- `ultimo_ok.csv` — lo reescribe cada corrida completa exitosa. Ignorado por git.
- `fichajes_semilla.csv` — viajaría con el repositorio para garantizar que el respaldo existe desde el primer clone.

Ojo con qué es este archivo

El respaldo **no es bronce**: es plata ya parseada. Sirve para salvar la corrida de hoy si las fuentes no responden, pero **no permite reprocesar nada**. El bronce es el que te salva de un bug en el parser.

4.6 Capa oro — no se construye acá

Sería el dataset ya listo para el modelo: features derivadas, agregados por liga. Se arma en las unidades 3 y 4 sobre esta misma plata.

Dónde termina la plata, exactamente. La línea es fácil de cruzar sin darse cuenta, y la cruzamos una vez, así que conviene dejarla escrita.

Un mapeo determinístico de una columna es **descripción** y va en la plata: `club_origen_liga_es_top5` sale del código de liga de esa misma fila y de nada más. Una columna cuyo valor depende de **cómo se agregan las demás filas** es una **feature** y no va en la plata.

El caso concreto: se probó agregar un `score_posicion` —el rendimiento previo normalizado en z dentro del grupo de posición— y se sacó. El z se calcula contra la media y el desvío del grupo, así que su valor **cambia según qué filas entren al análisis**. Si el análisis después restringe la población, el score correcto es el de esa población, no el de las 10.352 filas. Congelarlo en la plata es decidir por adelantado una pregunta que le toca al análisis.

Ese score vive ahora en el notebook de la Entrega 2 (`Proyecto_entrega_2/entrega2_grupo_7.ipynb`), junto con la decisión de sobre qué población se normaliza.

5. Las tres fuentes de datos

Fuente	Qué aporta	Cómo se accede
UEFA	ranking y coeficiente de clubes (diez temporadas) y de las 55 asociaciones	API JSON pública
Transfermarkt	el fichaje completo: jugador, origen, destino, importe, edad, liga	HTML, hay que parsearlo
FotMob	el rendimiento previo: 56 métricas por torneo	API interna, JSON

5.1 UEFA — de dónde sale la columna objetivo

La tabla que se ve en `es.uefa.com/nationalassociations/uefarankings/tenyears/` la arma JavaScript, y además ese host **no le contesta a un cliente HTTP pelado**: la conexión TLS se establece y el servidor no responde nunca (probado con

`urllib` y con `requests`). Scrapearla exigiría un navegador headless.

El mismo dato sale del backend que alimenta esa página, que sí responde y devuelve JSON:

```
https://comp.uefa.com/v2/coefficients
?coefficientType=MEN_CLUB_TEN_YEARS    coeficiente de clubes, 10 temporadas
&coefficientRange=OVERALL              acumulado, no una temporada suelta
&seasonYear=2027                       ventana que termina en 2026/27
&language=EN&page=1&pagesize=500
```

Los valores de esos dos enum salen del **contrato publicado de la API** (comp.uefa.com/v3/api-docs), no de adivinar.

Verificado contra la página: Bayern 267.500, Real Madrid 246.500, Man City 240.500, Liverpool 239.000.

Devuelve 554 clubes y, lo más útil para nosotros, un campo `lastUpdateDate`: la señal de frescura que usa el cortocircuito del DAG.

5.2 Transfermarkt — la fila trae más de lo que parece

Transfermarkt no tiene API pública, así que se usa scraping: se baja el HTML y se parsea con `BeautifulSoup`. Lo importante es que **una fila de la tabla de altas ya contiene todo lo necesario para describir el club de origen**, sin una request extra:

```
<a href="/fc-liverpool/startseite/verein/31" title="Liverpool FC"> id + slug
<img class="flaggenrahmen" title="England"> país
<a href="/premier-league/transfers/wettbewerb/GB1">Premier League liga + código
```

Y del jugador: id de Transfermarkt, **edad al momento del fichaje**, nacionalidad, posición y el id de la operación. Antes de este cambio, de todo eso sólo se leía el nombre del club de origen.

Por qué el dominio internacional

Se usa transfermarkt.com y no transfermarkt.com.ar. El dominio en español **traduce los nombres de club** ("Bayern Múnich", "SSC Nápoles", "Estrella Roja de Belgrado", "Club Brujas"), y esos nombres traducidos no cruzan contra el ranking de UEFA: sobre el mismo conjunto de clubes, la cobertura del cruce cae de 96% a 89%. De paso, el importe viene en un formato mucho más simple de parsear: €70.00m contra 70,00 mill. €.

5.3 FotMob — estadísticas y el problema de los homónimos

FotMob sí tiene endpoints internos accesibles que devuelven JSON, así que acá no hay HTML que parsear:

Endpoint	Para qué
<code>/api/data/search/suggest?term=</code>	buscar un jugador por nombre
<code>/api/data/playerData?id=</code>	perfil: edad, altura, país, pie hábil
<code>/api/data/playerStats?playerId=</code>	métricas detalladas de un torneo

El problema real de esta fuente es el cruce: Transfermarkt da el nombre, FotMob hay que buscarlo. Y **"Luis Díaz" devuelve tres jugadores distintos**: el del Bayern, uno del Alajuelense y uno de Peñarol. La versión anterior del código se quedaba siempre con la primera sugerencia, sin verificar nada — y un acierto silencioso no se distingue de un error silencioso.

Ahora se desambigua con lo que ya sabemos del fichaje: la sugerencia trae el club actual del jugador, así que se prefiere la que coincide con el club de destino o con el de origen del traspaso. Cuando no hay forma de decidir se usa igual la mejor sugerencia, **pero queda anotado el método** en el archivo de bronce, en el campo `match_metodo`:

Valor	Qué significa	Confianza
<code>club_destino</code>	la sugerencia coincide con el club al que fue	alta

Valor	Qué significa	Confianza
<code>club_origen</code>	coincide con el club del que salió	alta
<code>unica_sugerencia</code>	FotMob devolvió un solo jugador con ese nombre	media
<code>primera_sugerencia</code>	había varios y no se pudo decidir	el único dudoso

De los cinco valores, al dataset final llega sólo lo que cambia una decisión de análisis: si el cruce fue dudoso o no. Eso es la columna `cruce_dudoso` (11.4). Un cruce dudoso tiene que poder filtrarse después; lo que no se puede es no saber cuáles son.

6. El DAG paso a paso, con los conceptos de Airflow

El DAG se llama `pipeline_fichajes` y encadena **11 tareas**. Cada una introduce un concepto.

Concepto Airflow: DAG

Un DAG (*Directed Acyclic Graph*, grafo acíclico dirigido) es la unidad central de Airflow: describe un conjunto de tareas y el orden en que deben ejecutarse, sin ciclos. Se define con el decorador `@dag` sobre la función `pipeline_fichajes()`. **La última línea del archivo llama a esa función**: sin esa llamada el archivo se parsea sin errores y no aparece nada en la interfaz. Es uno de los olvidos más comunes.

6.1 `esperar_fuentes()` — `@task.sensor`

```
@task.sensor(poke_interval=300, timeout=1800, mode="reschedule", soft_fail=True)
def esperar_fuentes(**context) -> PokeReturnValue:
    actualizado = uefa.ultima_actualizacion(params["anio_uefa"])
    huella_tm = tm.huella_ultimos_traspasos(tm.bajar_ultimos_traspasos())
    ...
    return PokeReturnValue(is_done=True, xcom_value=huella)
```

Concepto Airflow: Sensor

Un sensor es una tarea que **espera a que se cumpla una condición** antes de dejar avanzar al resto del DAG. En vez de fallar si la condición no se cumple al instante, "tantea" (*poke*) cada cierto intervalo.

- `poke_interval=300` — sondea cada 5 minutos.
- `timeout=1800` — se rinde a la media hora. Un corte de diez minutos ya no arruina la corrida del día.
- `mode="reschedule"` — entre sondeo y sondeo **libera el worker** en vez de tenerlo durmiendo. Con un sensor da igual; con cincuenta esperando, es la diferencia entre un scheduler sano y uno tapado.
- `soft_fail=True` — al agotarse el tiempo la tarea queda en `skipped` y no en `failed`: que una fuente no conteste no es un error del pipeline, es una condición que sabemos manejar.

Los sensores son para lo que está **fuera del control del DAG**. Para esperar a una tarea del mismo DAG no hace falta un sensor: para eso están las dependencias.

Además de esperar, esta tarea **toma la huella de las fuentes** y la devuelve, que es lo que después decide si hay trabajo.

6.2 `elegir_camino()` — `@task.branch`

```
@task.branch(trigger_rule=TriggerRule.ALL_DONE)
def elegir_camino(**context) -> str:
    if context["ti"].xcom_pull(task_ids="esperar_fuentes"):
        return "hay_novedad"
    return "usar_respaldo"
```

Concepto Airflow: Branching

Una tarea `@task.branch` no devuelve datos: **devuelve el nombre de la tarea que sigue**. Airflow ejecuta esa rama y marca la otra como `skipped` — en la interfaz se ve en gris: no falló, no correspondía.

Corre con `ALL_DONE` porque la tarea de arriba **puede haber quedado en `skipped`**, que es justamente el caso que tiene que manejar. Con la regla por defecto nunca se ejecutaría cuando más falta hace.

6.3 `hay_novedad()` — `@task.short_circuit`

```
@task.short_circuit
def hay_novedad(**context) -> bool:
    huella = dict(context["ti"].xcom_pull(task_ids="esperar_fuentes") or {})
    if params["forzar"]:
        return True
    huella["alcance"] = f"{tope}/{temporadas}"
    anterior = Variable.get("fichajes_ultima_huella", default=None)
    if anterior == _serializar(huella):
        return False      # nada cambió: no hay nada que hacer
    return True
```

Concepto Airflow: Short-circuit

Es una tarea que actúa como un "if" a nivel de todo el flujo: si devuelve `False`, todas las tareas que dependen de ella quedan en `skipped` en lugar de ejecutarse, y **la corrida termina en éxito**. La mayoría de las corridas de un pipeline sano no hacen nada, y eso está bien; lo que no está bien es no darse cuenta.

Concepto Airflow: Variable

Las Variables son un almacén clave-valor persistente en la base de metadata de Airflow, accesible desde cualquier DAG. Acá `fichajes_ultima_huella` es lo que le da **memoria** al pipeline entre corridas.

Qué cambió acá, y por qué importa. La versión anterior preguntaba "¿pasaron 24 horas?". Un reloj responde cuánto hace que corriste, **no si la fuente cambió**: se podía correr a las 23:59 y otra vez a las 00:05 bajando exactamente lo mismo, o saltarse un mercado entero por haber corrido esa mañana. Ahora se compara una huella con cuatro componentes:

Componente	De dónde sale	Qué detecta
<code>uefa_actualizado</code>	<code>lastUpdateDate</code> de la API de UEFA	que se recalcularon los coeficientes
<code>tm_ultimos</code>	hash de los ids de la página de últimos traspasos	que se registraron fichajes nuevos
<code>temporada_actual</code>	deducida de la fecha	que arrancó una temporada nueva
<code>alcance</code>	los parámetros de la corrida	que alguien pidió más clubes o más temporadas

Por qué la sonda de Transfermarkt es la página de últimos traspasos

En la página del ranking de clubes se mueve el valor de mercado todo el tiempo: hashearla daría "hay novedad" en **todas** las corridas y el cortocircuito no cortaría nunca. La página de últimos traspasos cambia exacta y únicamente cuando se registra un traspaso, que es la pregunta que hay que responder.

Y hay un segundo arreglo, más sutil: **la marca se anota en la última tarea**, recién cuando el dataset pasó la validación. Antes se anotaba dentro del propio cortocircuito, así que una corrida que después fallaba dejaba igual al DAG creyendo que ya había procesado el día.

6.4 `aterrizar_bronce_uefa()` — `@task` y **XComs**

```
@task
def aterrizar_bronce_uefa(**context) -> dict:
    crudo = uefa.clubes_diez_temporadas(params["anio_uefa"])
    actualizado = (crudo.get("actualizado") or "")[:10]
    bronce.escribir_json(bronce.ruta_uefa_clubes(actualizado), crudo)
    ...
    return {"actualizacion": actualizado, "clubes": str(ruta_clubes), ...}
```

Concepto Airflow: TaskFlow API (@task) y XCom

El decorador `@task` convierte una función Python normal en una tarea. El valor que la función `returnea` se guarda automáticamente como un **XCom** (*cross-communication*): el mecanismo con el que Airflow pasa datos entre tareas, porque cada tarea corre en su propio proceso y no comparten memoria.

Y si una tarea recibe como argumento el resultado de otra, **Airflow deduce la dependencia solo**: no hace falta declararla.

La regla del XCom: por ahí viajan metadatos, no datos

Los XCom se guardan en la base de metadata de Airflow, que está pensada para registrar el estado de las corridas, no para almacenar datos. Por eso las tareas de bronce devuelven **rutas de archivo**, no el HTML. Pasar megabytes de página por XCom satura la base, y es de los errores más comunes al empezar.

La partición usa la fecha de actualización que informa la propia UEFA, **no la fecha de la corrida**: dos corridas del mismo snapshot escriben en la misma carpeta y no se duplica nada.

6.5 construir_catalogo() — el catálogo de clubes a procesar

Hace dos cosas:

1. Baja el ranking de clubes de Transfermarkt **y lo guarda en bronce**. De esa página sólo se usan el id y el slug; la posición la pone UEFA.
2. Cruza las dos fuentes por nombre (sección 8) y escribe `dim_clubes.csv` junto con el archivo de los que no cruzaron.

Devuelve la lista de clubes ordenada **por ranking de UEFA**. El orden importa: si una corrida se interrumpe, lo que alcanzó a bajar son los clubes que más pesan.

6.6 aterrizar_bronce_transfermarkt() — Dynamic Task Mapping

```
@task(map_index_template="{{ task.op_kwargs['club']['nombre'] }}")
def aterrizar_bronce_transfermarkt(club: dict) -> dict:
    ...

# en el flujo:
bronces_tm = aterrizar_bronce_transfermarkt.expand(club=catalogo)
```

Concepto Airflow: Dynamic Task Mapping (.expand())

En vez de escribir 200 tareas a mano (una por club), `.expand()` le dice a Airflow: "creá una instancia de esta tarea por cada elemento de la lista, **en tiempo de ejecución**". Cada una se llama *mapped task instance*. El número lo decide la fuente, no el código.

`map_index_template` existe porque, por defecto, las instancias mapeadas se numeran 0, 1, 2..., que es poco útil cuando querés saber cuál falló. Con esto, en la interfaz se lee "Bayern Munich" en verde y "Real Madrid" corriendo.

El paralelismo lo limitan dos parámetros del DAG:

- `max_active_tasks=4` — cuatro clubes a la vez, para no golpear a una fuente gratuita ni arriesgar un bloqueo de IP.
- `max_active_runs=1` — **una sola corrida por vez**. No es una precaución genérica: la capa plata lee la carpeta de bronce **entera**, así que si dos corridas se pisan, la que consolida primero arma el dataset con el bronce a medio escribir de la

otra. Nos pasó la primera vez que despausamos el DAG, y está contado en la sección 9.3.

Concepto Airflow: idempotencia y reintentos

Una tarea es **idempotente** cuando ejecutarla dos veces deja el mismo resultado que ejecutarla una. Suena teórico hasta la primera vez que un pipeline se cae por la mitad y hay que relanzarlo.

El DAG define `default_args={"retries": 2}`, o sea que **todas** las tareas reintentan dos veces ante un error. Eso sólo es seguro porque todas son idempotentes: las de bronce no vuelven a pedir lo que ya está en disco, la plata reconstruye el CSV entero, y **publicar** escribe siempre el mismo archivo fechado. Si una tarea agregara una fila en vez de reescribir el archivo, cada reintento duplicaría datos.

La única que pisa ese default es `validar_dataset_plata`, con `retries=0`: un chequeo de calidad que falla no es un error transitorio, es el dataset que está mal. Reintentarlo sólo demora el rojo.

La excepción a la regla `append-only` está acá:

```
def es_inmutable(temporada, temporada_actual):  
    return temporada < temporada_actual
```

- **Temporada cerrada:** si está en bronce, es definitiva. No se vuelve a pedir nunca.
- **Temporada en curso:** sí se vuelve a pedir, porque el mercado sigue abierto y Transfermarkt agrega altas. Pero si el contenido que llega es **idéntico** al que ya está en disco, no se reescribe: así la fecha del archivo sigue diciendo cuándo cambió el dato y no cuándo lo miramos.

6.7 aterrizar_bronce_fotmob() — la tarea que lee de disco

Lee las altas del HTML **que ya está en bronce** —no vuelve a Transfermarkt— y por cada fichaje pide a FotMob las estadísticas de la temporada **anterior** al traspaso. Si el archivo del jugador ya existe, lo saltea.

```
temporada_stats = tm.etiqueta_temporada(temporada_tm - 1)
```

Esa resta es el corazón del dataset: lo que se quiere explicar es a qué club fue el jugador **dado cómo venía rindiendo**, no cómo rindió después.

6.8 generar_capa_plata() — TriggerRule.ALL_DONE

```
@task(trigger_rule=TriggerRule.ALL_DONE)  
def generar_capa_plata(_lotes, **context) -> str | None:  
    return plata.consolidar(temporadas=temporadas)
```

Concepto Airflow: Trigger Rules

Por defecto, una tarea sólo se ejecuta si **todas** sus tareas anteriores terminaron en éxito (`all_success`, la regla implícita). Una *trigger rule* cambia esa condición.

`ALL_DONE` corre en cuanto todas las tareas anteriores terminaron, sin importar si fue con éxito, error o skip. Se usa acá para que un club que falló al bajar no tire abajo el dataset entero.

Esta tarea **no toca la red**: todo sale del bronce.

6.9 usar_respaldo() — la rama de último recurso

Devuelve el respaldo más fresco que haya en disco: primero el de la última corrida completa exitosa, y si no existe, la semilla del repositorio.

6.10 validar_dataset_plata() — NONE_FAILED_MIN_ONE_SUCCESS

```
@task(trigger_rule=TriggerRule.NONE_FAILED_MIN_ONE_SUCCESS)
def validar_dataset_plata(desde_fuente, desde_respaldo) -> str:
```

Recibe las dos ramas, y **una de las dos siempre viene salteada**. Con la regla por defecto esta tarea no se ejecutaría nunca. `NONE_FAILED_MIN_ONE_SUCCESS` dice "que ninguna haya fallado y que al menos una haya tenido éxito": salteada no es fallada, así que la condición se cumple.

6.11 publicar() — el entregable y la memoria

Escribe `include/output/fichajes_AAAA-MM-DD.csv`, refresca el respaldo y anota la huella de la corrida en la Variable.

Cuidado con ds

`ds` (la fecha lógica como texto) **sólo existe cuando el DAG tiene `schedule`** y por lo tanto intervalo de datos. Sacar la fecha del `DagRun` funciona en los dos casos, así que conviene por costumbre:

```
momento = dag_run.logical_date or dag_run.run_after
fecha = momento.date().isoformat()
```

6.12 Los parámetros de corrida

Concepto Airflow: Param

Un DAG puede declarar qué se le puede configurar al dispararlo. Eso hace dos cosas: valida los valores, y **genera un formulario en la interfaz** cuando elegís *Trigger DAG w/ config*.


Parámetro	Por defecto	Qué hace
<code>modo</code>	<code>normal</code>	<code>prueba</code> pisa todo: top 20 de UEFA y una temporada
<code>tope_ranking_uefa</code>	<code>200</code>	hasta qué puesto del ranking UEFA se procesan clubes de destino
<code>temporadas_hacia_atras</code>	<code>4</code>	cuántas temporadas de fichajes, desde la actual
<code>anio_uefa</code>	<code>2027</code>	ventana del ranking de diez años. Fijarlo hace la corrida reproducible
<code>forzar</code>	<code>false</code>	ignora la huella de frescura y vuelve a pedir todo
<code>exigir_estadisticas</code>	<code>false</code>	deja afuera a los jugadores sin temporada previa en FotMob

Los dos que conviene entender antes de tocarlos:

`temporadas_hacia_atras` es la palanca que rinde. Subir el tope del ranking de clubes no puede agregar un solo positivo (la tabla de la sección 1 lo muestra); una temporada más agrega ~2.700 filas y ~210 positivos con el mismo balance de clases.

`exigir_estadisticas` viene **apagado a propósito**. Prendido, el dataset pierde el 32,3% de las filas pero sólo el 25,3% de los positivos, y la clase positiva sube del 8,0% al 10,3%: es una restricción defendible. Pero la plata es la capa completa, y la partición de la población se declara **en el análisis**, donde se puede mostrar el contraste entre las dos poblaciones. Si el pipeline las borra, el gráfico que justifica la decisión no se puede dibujar. Existe para poder reproducir esa población desde el pipeline si alguna vez hace falta.

7. Diagrama del flujo completo



Concepto Airflow: el operador >>

El operador >> establece dependencias entre tareas ("A corre antes que B"). En este DAG **las únicas dependencias declaradas a mano son las de las tareas de decisión**, que no se pasan datos entre sí: sólo ordenan el flujo. El resto sale solo de que una tarea reciba como argumento el resultado de otra.

```

espera >> rama
rama >> [novedad, respaldo]
novedad >> uefa_bronce
publicar(validar_dataset_plata(tabla_plata, respaldo))
  
```

8. Cómo se cruzan los nombres de club (tokenización)

Este es el punto más delicado del pipeline, así que conviene entenderlo.

8.1 El problema

UEFA publica la posición y el coeficiente, **pero no el id de Transfermarkt**. Transfermarkt publica el id —que es lo único que arma la URL de fichajes— **pero su ranking es propio**. No hay ninguna clave compartida entre las dos fuentes: hay que cruzar por nombre. Y los nombres no coinciden literalmente:

Transfermarkt	UEFA
Inter Milan	FC Internazionale Milano
Ajax Amsterdam	AFC Ajax
Red Bull Salzburg	FC Salzburg
Athletic Bilbao	Athletic Club
Zorya Lugansk	FC Zorya Luhansk

8.2 Paso 1 — normalizar y tokenizar

Tokenizar es partir un texto en piezas (*tokens*) para poder compararlas de a una en vez de comparar el texto entero. La función `normalizar()` hace cuatro cosas:

```
def normalizar(texto):
    t = quitar_tildes(texto).lower()          # "FC Bayern München" -> "fc bayern munchen"
    t = re.sub(r"\(.*\?)", " ", t)           # borra "( - 2025)" y similares
    t = re.sub(r"[^a-z0-9 ]", " ", t)         # borra puntuación
    return [x for x in t.split() if x not in RUIDO]
```

1. Saca **tildes y caracteres especiales** ($\phi \rightarrow o$, $\delta \rightarrow d$, $\text{ı} \rightarrow l$, $\beta \rightarrow ss$).
2. Pasa todo a **minúsculas**.
3. Borra lo que va entre paréntesis y la puntuación.
4. **Parte en tokens y descarta las siglas que no distinguen nada**: `fc`, `cf`, `sc`, `ac`, `sk`, `fk`, `pfc`, `ssc`, `club`... Son ~60 siglas listadas en la constante `RUIDO`.

El resultado no es un texto sino una **lista de tokens**:

```
"FC Bayern München" -> ["bayern", "munchen"]
"Bayern Munich"     -> ["bayern", "munich"]
"AFC Ajax"           -> ["ajax"]
"Ajax Amsterdam"     -> ["ajax", "amsterdam"]
```

8.3 Paso 2 — bloquear por país

Antes de comparar nada, se filtran los candidatos de UEFA **al mismo país** que informa Transfermarkt. Esto es lo que evita cruces absurdos:

- "Zira FC" (Azerbaián) con "Gżira United FC" (Malta) — se parecen muchísimo.
- "ETO FC" (Hungría) con "Everton FC" (Inglaterra).

Hay cuatro países que las dos fuentes escriben distinto y se mapean a mano: `Czech Republic` → `Czechia`, `Bosnia-Herzegovina` → `Bosnia and Herzegovina`, `Ireland` → `Republic of Ireland`, y `Monaco` → `France` (Mónaco no es una asociación de UEFA: el AS Monaco compite dentro de la federación francesa).

8.4 Paso 3 — comparar, en tres intentos y en este orden

a) **Exacto**. Las dos listas de tokens son idénticas.

```
["bayern", "munchen"] == ["bayern", "munchen"] → cruce exacto
```

UEFA publica cuatro formas de cada nombre (`displayName`, `displayOfficialName`, `internationalName`, `displayNameShort`), así que se prueba contra las cuatro. La mayoría cruza acá.

b) Subconjunto de tokens. Si **todos** los tokens de un nombre están contenidos en el otro, es el mismo club. Resuelve el caso más común: que una fuente agregue la ciudad y la otra no.

```
{"ajax"}      {"ajax", "amsterdam"}      → AFC Ajax = Ajax Amsterdam
{"salzburg"} {"red", "bull", "salzburg"} → FC Salzburg = Red Bull Salzburg
```

Este paso **sólo se aplica si estamos bloqueados por país**. Sin esa restricción "Inter" matchearía con medio continente.

c) Aproximado. Recién acá se mide parecido de texto, con `SequenceMatcher` de la biblioteca estándar, que devuelve un número entre 0 y 1. Se acepta desde 0,82 **dentro del país** (o 0,93 si no se pudo bloquear por país). Absorbe transliteraciones:

```
"zorya lugansk" vs "zorya luhansk" → 0,92 → cruce aproximado
```

Si ninguno de los tres da resultado, el club va a `dim_clubes_sin_cruce.csv` y queda afuera del catálogo. **No se inventa un cruce.**

8.5 El resultado, medido

Sobre los 522 clubes únicos del catálogo:

Método	Clubes
Exacto	409
Subconjunto de tokens	85
Aproximado	13
Sin cruce	15
Cobertura	97,1%

Y **los 20 primeros de UEFA cruzan todos**, que es lo que más importa porque de ahí sale la columna objetivo. De los 14 que no cruzan, **3 son clubes rusos** —excluidos de las competiciones de UEFA desde 2022, así que no figuran en el ranking y no cruzarlos es lo correcto— y el resto son clubes muy chicos.

Cada fila del dataset lleva **con qué método cruzó cada uno de sus dos clubes**, en `cruce_dudoso`, que marca las filas donde alguno de los dos clubes cruzó sólo por parecido de texto.

8.6 El mismo mecanismo, reutilizado en FotMob

La desambiguación de homónimos de la sección 5.3 usa el mismo `normalizar()`: compara los tokens del club que devuelve FotMob contra los tokens del club de destino y del de origen. Si comparten al menos un token, es el jugador que buscábamos.

9. Cómo correrlo: modo prueba y prueba local

Hay dos maneras de correr el pipeline en chico, y sirven para cosas distintas.

9.1 Modo prueba — el DAG entero, con poco volumen

Es el **DAG de verdad**, con las 11 tareas, corriendo en Airflow, pero con el alcance recortado. Se dispara desde la interfaz con *Trigger DAG w/ config* y `modo = prueba`.

```
def _alcance(params):
    if params["modo"] == "prueba":
        return 20, 1 # top 20 de UEFA, una sola temporada
    return params["tope_ranking_uefa"], params["temporadas_hacia_atras"]
```

El modo **prueba** **pisa los dos parámetros numéricos**: 20 clubes y una temporada en lugar de 200 y 3. Eso baja la corrida de un par de horas a unos pocos minutos.

Para qué sirve: para ver el grafo moverse entero. Se ven las 20 instancias de `.expand()` corriendo de a cuatro, cada una con el nombre de su club; se ve el sensor pasar a verde; y si lo disparás dos veces seguidas, la segunda termina en segundos y casi todo queda en gris, porque **hay_novedad** cortó. Es la forma de entender el DAG, y la que conviene usar para mostrarlo.

Qué NO prueba: el volumen. Con 20 clubes el dataset no llega al mínimo de 1000 filas, así que la tarea de validación va a fallar a propósito. Eso no es un bug: es la validación haciendo su trabajo.

9.2 Prueba local — sin Airflow, para depurar el parseo

```
py -m include.fichajes.prueba_local --clubes 3 --temporadas 1
py -m include.fichajes.prueba_local --clubes 3 --temporadas 1 --sin-fotmob
```

`prueba_local.py` hace **lo mismo que el DAG pero en un solo proceso de Python**, sin contenedores, sin scheduler y sin base de metadata: baja el ranking de UEFA, arma el catálogo, baja las altas de N clubes, consulta FotMob y escribe la capa plata. Escribe en las mismas carpetas **bronze/** y **silver/** que el DAG, así que lo que baja **se reusa** después.

Para qué sirve: para depurar. Cuando estás cambiando el parseo de una tabla o agregando una columna, levantar Docker y esperar al scheduler para cada prueba es insoportable. Acá el ciclo es de segundos y los errores salen directos en la terminal, con el traceback completo.

Opción	Qué hace
<code>--clubes N</code>	cuántos clubes del top de UEFA procesar
<code>--temporadas N</code>	cuántas temporadas hacia atrás
<code>--sin-fotmob</code>	saltea el paso lento y arma la plata con lo que ya haya en bronce
<code>--anio-uefa</code>	qué ventana del ranking usar

`--sin-fotmob` es la opción más útil de las cuatro: FotMob es lo que hace lenta la corrida (unas 3 requests por jugador, con pausas), y si lo que estás depurando es el parseo de Transfermarkt o el enriquecimiento, no lo necesitás.

Es una herramienta de desarrollo, no el pipeline. El pipeline es el DAG. `prueba_local.py` no tiene sensor, ni reintentos, ni cortocircuito, ni paralelismo, ni validación: baja todo de corrido. Sirve para que el ciclo de depuración sea rápido, nada más.

9.3 Qué pasa cuando lo despausás — leelo antes de hacerlo

La primera corrida real nos dejó dos lecciones que conviene tener antes de apretar el interruptor.

1. Despausar el DAG dispara una corrida enseguida, con los parámetros por defecto. El DAG tiene `schedule="0 6 * * *"` y `catchup=False`. Al despausarlo, Airflow programa la corrida del intervalo más reciente, y esa corrida **no lleva la configuración que vos elegiste en el formulario**: va con los valores por defecto, o sea 200 clubes y 4 temporadas. Eso es más de una hora de scraping. Si lo único que querés es ver el grafo moverse, disparalo a mano con `modo = prueba` y dejá el DAG pausado.

Y si disparaste una corrida a mano **antes** de despausar, la programada se te adelanta y la tuya queda encolada detrás por `max_active_runs=1`. No se pierde: se ejecuta después, y como para entonces la huella ya coincide, corta en **hay_novedad** y termina en verde sin bajar nada.

2. Dos corridas en paralelo se pisan. Nos pasó exactamente eso: la corrida manual de prueba (20 clubes) y la programada (200 clubes) corrieron a la vez. Las dos escriben en la misma carpeta de bronce, y la capa plata **lee la carpeta entera**, así que la prueba consolidó 582 filas de 110 clubes cuando debería haber consolidado ~120 de 20.

No fue un error de datos —las 582 filas eran correctas—, pero sí un resultado que no se correspondía con lo que la corrida había pedido. La solución es `max_active_runs=1` en el DAG, que ya está puesto: Airflow encola la segunda corrida hasta que la primera termine.

Es un ejemplo de algo que vale la pena entender: **el bronce es estado compartido entre corridas**. Esa es justamente su gracia (por eso la segunda corrida no vuelve a pedir nada), pero significa que dos corridas simultáneas no son independientes.

3. Pausar el DAG congela la corrida que está en curso. Esto sorprende, porque uno esperaría que pausar sólo impida que arranquen corridas nuevas. No es así: el scheduler **no programa tareas de un DAG pausado**, ni siquiera las de una corrida que ya empezó. Pausarlo con 188 tareas por delante las deja a todas en `scheduled` y no avanza ninguna.

El orden correcto es: despausar, dejar que la corrida termine, y **recién entonces** pausar.

10. Validación de calidad de datos

La tarea `validar_dataset_plata` actúa como auditor antes de dar el pipeline por exitoso. Si cualquier chequeo falla, lanza un `ValueError`, el DAG queda en rojo y **publicar no corre**: el dato malo no llega a destino.

Un criterio de calidad que no está escrito como código no protege nada. Los diez chequeos cubren las cinco dimensiones canónicas:

Dimensión	Chequeo
Unicidad	<code>operacion_id</code> sin repetidos
Compleitud	ninguna columna del esquema falta; ninguna 100% vacía; las obligatorias sin un solo nulo. <code>coste_fichaje_eur</code> y <code>club_origen</code> no están entre las obligatorias: sus nulos son legítimos y están explicados en 12.3
Volumen	al menos 1000 filas y 30 columnas
Precisión	edad entre 14 y 45; altura entre 140 y 220 cm; importes no negativos
Consistencia	<code>es_destino_top_20</code> tiene que coincidir con <code>club_destino_ranking_uefa ≤ 20</code> ; ningún club de destino puede quedar sin ranking; ninguna operación de las excluidas puede haberse colado; <code>tiene_historial</code> tiene que coincidir con tener métricas <code>stat_*</code>

El chequeo de unicidad es el **test operativo de la unidad de análisis**: si la clave repite, o la unidad está mal definida o el pipeline duplica. Y tiene que correr sobre una clave que **venga de la fuente**, no sobre una que el propio pipeline haya forzado deduplicando — si no, confirma una propiedad que acaba de imponer (ver 11.1).

Los de consistencia son los más útiles de todos. El primero verifica que la columna objetivo sea realmente una función del ranking y no un valor que se coló de otro lado. El segundo cubre el modo de falla silencioso que tendría: si un club de destino no cruzara contra UEFA, su ranking quedaría nulo y `es_destino_top_20` saldría en **False por omisión**, no por el dato — la etiqueta quedaría mal sin que nada se queje.

El cuarto es el que cuida el bloque de FotMob: si `tiene_historial` dijera **True** en una fila sin ninguna métrica, o al revés, o el flag miente o las `stat_*` se perdieron al consolidar. Es un chequeo que mira la **coherencia interna de la fila**, sin depender del resto del dataset — que es la única clase de chequeo que corresponde a esta capa.

La validación no exige cero nulos, y la distinción importa: nulos parciales son esperables y explicables (sección 12.3); una columna entera en nulo indica que algo se rompió.

11. Unidad de análisis y diccionario de columnas

11.1 Una fila es un fichaje

La entidad de estudio no es "el jugador" sino **el traspaso**: un jugador que llegó a un club en una temporada concreta, con sus estadísticas de la temporada **anterior** al traspaso.

El mismo jugador aparece más de una vez si fue transferido más de una vez dentro de la ventana que recorre el DAG, y no es raro: sobre las 10.352 filas hay 8.260 jugadores distintos — **1.618 aparecen más de una vez** y 386 aparecen tres veces o más.

Esto importa para la Unidad 3. Las filas **no son independientes**. Separar entrenamiento y prueba al azar dejaría al mismo jugador de los dos lados, y el modelo se evaluaría sobre gente que ya vio. La partición tiene que ser **por jugador o por temporada**, no por fila.

La **clave primaria** es `operacion_id`, el identificador que Transfermarkt le da a cada traspaso. Es la clave natural: si la unidad de análisis es el fichaje, la clave tiene que identificar un fichaje.

Esto también se corrigió, y vale la pena contarlo

La clave anterior era (`jugador_tm_id`, `temporada_fichaje`), y estaba mal: un jugador puede ser transferido **dos veces en la misma temporada**. Álvaro Morata en 2024/25 es el caso de manual — fue del Atlético al Milan por 17,2 millones y del Milan al Galatasaray por 6.

Con la clave vieja, esos dos fichajes colapsaban en una fila y el otro se perdía **sin avisar**. Sobre el bronce que teníamos eran 52 pares, un 2% de las filas. Lo raro es que el chequeo de unicidad pasaba igual: estaba verificando que la clave no repitiera *después* de deduplicar, así que confirmaba una propiedad que el propio código acababa de forzar.

Las dos temporadas son dos columnas distintas

Antes había una sola columna `temporada` que guardaba la temporada de las *estadísticas*, mientras la documentación la describía como "temporada del fichaje". Eran dos cosas distintas con un solo nombre, y se prestaba a confusión. Ahora:

- `temporada_fichaje` — cuándo ocurrió el traspaso, ej. **2026/2027**.
- `temporada_stats` — de qué temporada son las métricas: la anterior, **2025/2026**.

Un jugador puede aparecer dos veces en el mismo club y la misma temporada

Y no es un error: es una **cesión con opción de compra**. El jugador llega cedido y más adelante, en la misma temporada, el club ejecuta la opción. Transfermarkt lo registra como dos operaciones con dos ids distintos, porque son dos contratos.

Tammy Abraham -> Beşiktaş 2025/26 `cesion_con_cargo` € 2.000.000
Tammy Abraham -> Beşiktaş 2025/26 `compra` € 15.000.000

Son 15 casos. Para el análisis conviene saberlo: si contás "cuántos jugadores llegaron a un club top", esos cuentan dos veces. Si contás operaciones, una vez cada una, que es lo correcto.

11.2 Qué operaciones entran al dataset

Transfermarkt lista como "alta" seis cosas distintas, y no todas son un fichaje. Sobre las 11.806 altas del bronce:

tipo_operacion	filas	¿entra?	por qué
compra	2.646	sí	
desconocido	2.072	sí	hubo fichaje; Transfermarkt no publicó la cifra
libre	1.674	sí	un Bosman es un fichaje real
cesion	960	sí	

tipo_operacion	filas	¿entra?	por qué
cesion_con_cargo	293	sí	
fin_de_cesion	4.161	no	no es un fichaje

Por qué fin_de_cesion queda afuera. El texto literal de Transfermarkt es *End of loan 30/06/2024*: el jugador **vuelve a su propio club** después de un préstamo. No hubo decisión de fichar a nadie. Y hay un problema peor: en esas filas *club_origen* es *dónde estuvo cedido*, así que todo el enriquecimiento del club de origen estaría midiendo otra cosa.

Por qué el resto entra, aunque no tenga precio. La versión anterior se quedaba sólo con los fichajes con importe publicado. Eso parece prudente y no lo es: el importe **no es una propiedad del jugador antes del traspaso**, se negocia *con* el club de destino en el mismo momento en que se decide el destino. Filtrar por "tiene precio" es condicionar la muestra sobre una variable que se determina junto con la variable objetivo.

Hay algo más fuerte todavía, que se midió al preparar la Entrega 2: **el nulo del importe no es un dato faltante, es un nulo estructural**. *coste_fichaje_eur* está presente exactamente en las compras y las cesiones con cargo, y ausente exactamente en las cesiones, los libres y los desconocidos — **en 10.351 de las 10.352 filas**. Un pase libre no tiene monto porque no hay monto. Filtrar por "tiene precio" no es limpiar datos: es filtrar por *tipo_operacion* con otro nombre.

Y el efecto es medible, porque los fichajes sin importe no se reparten parejo:

	altas a clubes NO top 20	altas a clubes TOP 20
compra	32,1%	56,2%
libre	23,4%	7,9%
desconocido	27,7%	20,5%

Los clubes de afuera del top 20 fichan a coste cero tres veces más seguido. El filtro viejo borraba negativos de forma despareja e inflaba la clase positiva del 8,0% al 13,6%: el dataset decía que llegar a un club top es casi el doble de común de lo que es.

	filas	positivos	clase positiva
filtro viejo (sólo con importe)	3.913	532	13,6%
ahora (todo menos fin_de_cesion)	10.352	825	8,0%

El filtro se lleva el 62,2% de las filas y **el 35,5% de los positivos**, deja la muestra en 90% compras y derrumba los filiales del 19,6% al 2,6%. Y los efectos que se quieren medir **empeoran**: la separación estandarizada del coeficiente UEFA del país de origen baja de 1,088 a 0,798, o sea de verde a amarillo.

El importe se conserva como columna con nulos, y *tipo_operacion* dice si fue libre o si la cifra no se publicó. **Qué filas usar es una decisión del análisis, no del pipeline.**

11.3 Los clubes filiales

club_origen puede ser un filial o un juvenil: "Chelsea FC U21", "SL Benfica B", "FC Bayern Munich II". Son el **19,7% de las filas**, y casi todas son promociones sin cargo desde la cantera.

El cruce por subconjunto de tokens (sección 8.4) los confundía con el primer equipo, porque {"chelsea"} {"chelsea", "u21"}:

```
Manchester City U21 -> heredaba ranking UEFA 3
Arsenal FC U21     -> heredaba ranking UEFA 7
Chelsea FC U21     -> heredaba ranking UEFA 8
SL Benfica B       -> heredaba ranking UEFA 20
```

Un canterano promovido del U21 del City no es "un jugador que llegó desde el 3º mejor club de Europa" — son dos fenómenos distintos y el dataset los estaba confundiendo. Ahora se detectan por el sufijo, se marcan con `club_origen_es_filial` y **no heredan el ranking**: sus columnas de ranking y coeficiente quedan nulas.

11.4 Las columnas

Identificación

Columna	Descripción
<code>jugador_tm_id</code>	id del jugador en Transfermarkt. Clave estable de la fuente
<code>jugador_fotmob_id</code>	id en FotMob. Nulo si no se lo pudo cruzar
<code>nombre</code>	nombre del jugador, según Transfermarkt
<code>temporada_fichaje</code>	temporada del traspaso
<code>temporada_stats</code>	temporada de las métricas: la anterior al traspaso
<code>operacion_id</code>	id del traspaso en Transfermarkt

La operación

Columna	Descripción
<code>coste_fichaje_eur</code>	importe en euros, convertido desde €70.00m . Nulo en los fichajes libres y en los que no publicaron la cifra: el 53,7%
<code>tipo_operacion</code>	<code>compra</code> , <code>desconocido</code> , <code>libre</code> , <code>cesion</code> o <code>cesion_con_cargo</code> (ver 11.2)

Club de destino

Columna	Descripción
<code>club_destino</code> , <code>club_destino_id</code> , <code>club_destino_pais</code>	quién lo compró
<code>club_destino_ranking_uefa</code> , <code>club_destino_coeficiente_uefa</code>	del ranking de diez temporadas
<code>es_destino_top_20</code>	variable objetivo: <code>club_destino_ranking_uefa ≤ 20</code>

Club de origen — el enriquecimiento nuevo

Columna	Descripción
<code>club_origen</code> , <code>club_origen_id</code>	de dónde salió. Nulo, o <code>Without Club</code> , si llegó sin contrato: 82 filas
<code>club_origen_es_filial</code>	si es un filial o juvenil del estilo "Chelsea FC U21" (ver 11.3)
<code>club_origen_pais</code>	país del club de origen
<code>club_origen_liga</code> , <code>club_origen_liga_id</code>	liga y su código (GB1, ES1, NL1...)
<code>club_origen_liga_es_top5</code>	si la liga es una de las cinco grandes
<code>club_origen_es_europeo</code>	si el país es una de las 55 asociaciones de UEFA
<code>club_origen_ranking_uefa</code> , <code>club_origen_coeficiente_uefa</code>	nulos si el club no está entre los 554 del ranking, o si es un filial
<code>club_origen_es_top_20</code> , <code>club_origen_es_top_50</code>	derivadas del ranking

Columna	Descripción
<code>club_origen_pais_ranking_uefa</code> , <code>club_origen_pais_coeficiente_uefa</code>	fuerza del país, del ranking de asociaciones

Derivadas del par origen-destino

Columna	Descripción
<code>traspaso_domestico</code>	si origen y destino son del mismo país
<code>salto_ranking_uefa</code>	posiciones saltadas (origen – destino)
<code>sube_de_categoria</code>	si el salto fue hacia arriba

Biografía del jugador

Columna	Descripción
<code>edad_al_fichaje</code>	edad al momento del traspaso, según Transfermarkt
<code>nacionalidad</code> , <code>nacionalidad_2</code>	de las banderas de la fila. El 36% de los jugadores tiene dos
<code>posicion_tm</code>	posición nominal, según Transfermarkt. Sin nulos : es la que conviene usar
<code>posicion_fotmob</code>	dónde jugó de hecho, según FotMob. Sólo existe si hubo cruce
<code>altura_cm</code> , <code>pie</code>	del perfil de FotMob

Linaje — cuánto confiar en cada fila

Columna	Descripción
<code>tiene_historial</code>	si el jugador tiene estadísticas de la temporada previa
<code>cruce_dudoso</code>	si algún cruce por nombre de esta fila pudo salir mal
<code>uefa_actualizado_el</code>	snapshot del ranking usado para etiquetar
<code>extraido_el</code>	cuándo se armó la fila

Estas cuatro no describen al fichaje: describen **cuánta confianza merece la fila**. `cruce_dudoso` vale `True` en dos casos, los únicos donde el pipeline tuvo que adivinar:

- el jugador se eligió entre **homónimos** sin poder verificar cuál era;
- alguno de los dos clubes cruzó contra UEFA **sólo por parecido de texto**.

Son el 7,9% de las filas. El resto de los casos no necesita una columna propia porque ya está en otra: un filial está en `club_origen_es_filial`, un club fuera del ranking se ve en `club_origen_ranking_uefa` nulo, y la falta de estadísticas, en `tiene_historial`. **El detalle de cómo cruzó cada cosa queda en el bronce**, que es donde corresponde: la plata se queda con la conclusión, no con el procedimiento.

Para qué sirve en la práctica. Para poder revisar un resultado en vez de creerle:

```
confiable = df[~df["cruce_dudoso"]]
```

Si un hallazgo se da vuelta al sacar esas filas, no era un hallazgo: era un error de cruce.

Fue lo que encontró un error de verdad

El problema de los filiales (11.3) apareció exactamente así, mirando qué filas habían cruzado por parecido en vez de por nombre exacto: ahí saltó que "Chelsea FC U21" estaba cruzando contra Chelsea. Sin ese rastro, el dataset habría dicho que 1.504 canteranos venían de clubes de élite y no habría habido forma de notarlo: el número se ve perfectamente razonable.

Seis columnas que se sacaron. Una columna derivada se gana el lugar si encodifica una **decisión**; si es una cuenta obvia sobre otra columna, es ruido. `club_origen_es_top_20` se queda porque encodifica dónde está el corte; estas no encodificaban nada:

se sacó	porque era
<code>tiene_importe</code>	<code>coste_fichaje_eur.notna()</code>
<code>tiene_doble_nacionalidad</code>	<code>nacionalidad_2.notna()</code>
<code>pais_fotmob</code>	idéntica a <code>nacionalidad</code> en el 93,9% de las filas, y las diferencias eran de ortografía ("Ivory Coast" / "Cote d'Ivoire")
<code>match_metodo</code>	una partición perfecta de <code>tiene_historial</code> , salvo un valor
<code>cruce_club_destino_metodo</code> , <code>cruce_club_origen_metodo</code>	sus valores ya estaban en <code>club_origen_es_filial</code> y en el ranking nulo
<code>stat_conceded</code>	idéntica a <code>stat_goals_conceded</code> en las 2.244 filas comparables: FotMob publica la misma métrica con dos títulos

Las tres últimas se resumieron en `cruce_dudoso`. El dataset pasó de 113 a 107 columnas sin perder información.

Métricas — `stat_*`

65 columnas en la corrida actual: `stat_goals`, `stat_minutes`, `stat_xg`, `stat_pass_accuracy`, `stat_rating`... El total del dataset es **107 columnas: 42 descriptivas + 65 métricas**.

Las columnas `stat_*` no son una lista fija

A diferencia de las biográficas, las métricas se generan **dinámicamente** a partir de lo que la API de FotMob devuelve para cada jugador. Si a un jugador le faltan ciertas stats, esas columnas quedan nulas para esa fila.

Cuando un jugador tiene liga, copa y Champions en la misma temporada, las métricas **acumulativas se suman** (goles, minutos) y los **porcentajes y el rating se promedian**, porque sumarlos no significaría nada.

Limitación conocida, y conviene decirla antes de que la pregunten

El promedio **no está ponderado por minutos**. Un jugador con 3000 minutos de liga y 90 de copa pesa igual en los dos torneos. Corregirlo es trabajo de la capa oro, donde se arman las features del modelo.

12. Lo que hay que saber explicar (defensa oral)

Hay preguntas que ningún script valida. Aquí están contestadas con hechos concretos del código.

12.1 «Una fila es un ___»

Una fila es un **fichaje**: un jugador transferido a un club, en una temporada concreta, con sus estadísticas de la temporada previa al traspaso. No es "un jugador" (ver 11.1). Encaja con la pregunta del proyecto porque lo que se quiere explicar es una propiedad del **evento de fichaje** (a qué tipo de club fue), no una propiedad fija del jugador.

12.2 Columna objetivo, y por qué cambió

`es_destino_top_20` (booleana): si el club de destino está entre los 20 primeros del **coeficiente de clubes de UEFA de las últimas diez temporadas**.

Antes salía del orden del ranking propio de Transfermarkt: "estaba entre los primeros 20 de la tabla en el momento en que corrió el scraper". Esa tabla se reordena con los resultados de cada semana, así que **la etiqueta de un mismo fichaje podía cambiar entre dos corridas sin que nadie tocara el código**. El coeficiente de UEFA es una medida publicada, estable y auditable, y el snapshot exacto que se usó queda en la columna `uefa_actualizado_el`.

Junto con ese cambio hubo otras cinco correcciones de datos:

Qué estaba mal	Cómo se arregló
La edad al fichaje se estimaba: <code>edad_hoy - (2026 - año)</code> , con el 2026 escrito a mano y sin tener en cuenta el mes de nacimiento	Transfermarkt publica la edad al momento del traspaso en la misma fila que ya leíamos
La temporada actual estaba hardcodeada (<code>temporada_actual_tm = 2026</code>)	se deduce de la fecha: en Transfermarkt <code>season_id=2025</code> es la temporada 2025/26, y las ligas arrancan en julio
La búsqueda en FotMob se quedaba con <code>sugerencias[0]</code> sin verificar	se desambigua por club, y si no se pudo, la fila queda marcada con <code>cruce_dudoso</code>
Los fichajes sin estadísticas desaparecían sin dejar rastro	se conservan con las métricas en nulo y <code>tiene_historial=False</code>
El filtro de cesiones estaba adentro del scraping, comparando texto en español	<code>limpiar_importe()</code> devuelve (<code>euros</code> , <code>tipo_operacion</code>) y el filtro se aplica una sola vez, en la capa plata, contando en el log las filas descartadas

12.3 Por qué hay nulos

Los nulos no son aleatorios — cada uno tiene un origen identificable:

Columna	Por qué puede ser nula
<code>coste_fichaje_eur</code>	nulo estructural : la operación no tuvo monto. Son el 62,2%, y coincide con <code>tipo_operacion {cesión, libre, desconocido}</code> en 10.351 de 10.352 filas
<code>club_origen</code>	el jugador llegó sin contrato . Szczesny a Barcelona en 2024/25 es el caso. 216 filas
<code>stat_*</code>	no son fijas: FotMob no reporta la misma métrica para todos los jugadores. No es que falló la extracción
todas las <code>stat_*</code> de una fila	el jugador no se pudo cruzar, o no tiene métricas esa temporada. Lo dice <code>tiene_historial</code>
<code>club_origen_ranking_uefa</code>	el club de origen no está entre los 554 del ranking —le pasa a todo club no europeo y a los europeos chicos— o es un filial (11.3). Es información, no un hueco
<code>club_origen_liga</code>	Transfermarkt no informa la liga, típicamente en clubes de fuera de Europa
<code>altura_cm, pie</code>	FotMob no los informa para ese jugador
<code>salto_ranking_uefa</code>	requiere que los dos clubes estén en el ranking

Los nulos de stat_* son informativos, no un defecto

Sobre la corrida completa —10.352 fichajes, 188 clubes hasta el puesto 200 del ranking, 4 temporadas— el **32,3% no tiene estadísticas**. No es un fallo aleatorio de FotMob: la falta se concentra en un perfil muy concreto de jugador.

tasa de filas sin estadísticas	
jugadores de 28 años o más	15,6%
jugadores de 18 o menos	71,6%
que vienen de un club europeo del ranking	18,5%
que vienen de un filial o juvenil	69,3%

Son jugadores muy jóvenes, sobre todo canteranos, que todavía no habían acumulado minutos profesionales. La ausencia es el dato: marca la vía "promesa joven" de entrada a un club top.

Descartarlas cuesta: el dataset baja de 10.352 a 7.005 filas, la edad mediana sube de 23 a 24 años, y se pierden **115 de los 825 casos positivos**. La clase positiva sube del 8,0% al 10,1%, porque los clubes de abajo del ranking tienen más fichajes sin historial que los de arriba: el filtro no sólo achica, sesga.

Dicho esto, es un sesgo **mucho más suave que el del precio**: se lleva el 32,3% de las filas pero sólo el 13,9% de los positivos, mientras que el filtro de precio se llevaba el 62,2% de las filas y el 35,5% de los positivos. Por eso el análisis de la Entrega 2 sí restringe la población —declarándolo— y el parámetro `exigir_estadisticas` existe en el DAG. Lo que no hace el pipeline es aplicarlo por su cuenta.

Un bug que tuvo esto tapado

FotMob devuelve las métricas en dos lugares y no siempre manda los dos: `topStatCards` trae el resumen (goles, asistencias, minutos, rating) y `statsSection` el detalle (pases, duelos, xG y unas cincuenta más).

La función `metricas_de_torneo()` cortaba apenas faltaba `statsSection`, y tiraba también el resumen que sí había llegado. Esos jugadores quedaban como "sin estadísticas" teniendo goles y minutos publicados. Pasa sobre todo en ligas chicas: **el 13% de las filas sin datos**, unas 370, se recuperan con el arreglo — con seis métricas cada una en vez de las 56 del detalle completo.

12.4 Qué pasa si se corre de nuevo

El mismo día, sin que las fuentes cambien: sale exactamente lo mismo. El cortocircuito corta y ni siquiera se pide nada. Y si se fuerza con `forzar=true`, el bronce está en disco y la plata se reconstruye igual.

En otra fecha: no se garantiza, por motivos concretos:

- Transfermarkt y FotMob son sitios en vivo: se agregan fichajes y se corrigen importes.
- El ranking de UEFA se recalcula, así que un club puede entrar o salir del top 20 y cambiar la etiqueta de fichajes viejos.
Por eso `uefa_actualizado_el` está en el dataset: dice contra qué snapshot se etiquetó. El parámetro `anio_uefa` permite fijar la ventana, y es la palanca de reproducibilidad.
- Lo que **no** cambia por una corrida repetida es el bronce de temporadas cerradas: eso es inmutable por diseño.

12.5 Dónde queda el dato crudo

En `include/bronze/`, y ahora están **las tres fuentes**: el HTML de Transfermarkt, el JSON de UEFA y el de FotMob. Eso permite reconstruir la capa plata entera sin volver a pedirle nada a nadie, que es exactamente lo que se hace cada vez que se corrige el parseo o se agrega una columna derivada.

En la versión anterior sólo quedaba el JSON de FotMob, así que cualquier arreglo en el parseo del fichaje obligaba a scrapear Transfermarkt de nuevo.

12.6 Qué columnas NO se le pueden dar a un modelo

Esto no cambia el pipeline —la plata las conserva todas— pero es lo primero que hay que saber antes de usar el dataset, y es fácil equivocarse.

El momento de predecir es **justo antes de que el fichaje ocurra**. Ahí se sabe quién es el jugador, de dónde viene y cómo le fue la temporada pasada. **No** se sabe a dónde va, ni cuánto se pagó, ni bajo qué figura: todo eso se define *en* el fichaje, que es el evento que se quiere predecir.

Con ese criterio, **once columnas quedan afuera**:

Bloque	Columnas	Por qué
Destino	<code>club_destino</code> , <code>club_destino_id</code> , <code>club_destino_pais</code> , <code>club_destino_ranking_uefa</code> , <code>club_destino_coeficiente_uefa</code>	la columna objetivo es <code>club_destino_ranking_uefa</code> <code><= 20</code>
Par origen-destino	<code>traspaso_domestico</code> , <code>salto_ranking_uefa</code> , <code>sube_de_categoria</code>	las tres se calculan usando el club de destino. <code>salto_ranking_uefa</code> es literalmente <code>ranking_origen - ranking_destino</code>
La operación	<code>coste_fichaje_eur</code> , <code>tipo_operacion</code>	se definen en el mismo acto que el destino

Son, justamente, las que mejor "predicen": `club_destino_coeficiente_uefa` da una separación estandarizada de 4,1 y `coste_fichaje_eur` de 1,0. Un modelo con cualquiera de las dos acertaría casi todo, **por el peor de los motivos**.

Una trampa menos obvia. Contar cuántas veces aparece un jugador en el dataset separa muchísimo —5,5% de tasa con un fichaje, 9,7% con dos, **17,6% con tres o más**— y es tentador usarlo como variable. No se puede: ese conteo incluye traspasos **futuros**, que en el momento de predecir todavía no ocurrieron. Sólo valdría contando los anteriores a la fila.

13. Glosario rápido de Airflow

Término	Qué es
DAG	grafo de tareas con dependencias, sin ciclos; define un pipeline
Task / <code>@task</code>	unidad mínima de trabajo dentro de un DAG (TaskFlow API)
Operator	clase que define qué hace una tarea (versión clásica, pre-TaskFlow)
Sensor	tarea que espera a que se cumpla una condición externa
<code>mode="reschedule"</code>	el sensor libera el worker entre sondeos en vez de ocuparlo
<code>soft_fail</code>	al agotarse el tiempo el sensor queda en <code>skipped</code> , no en <code>failed</code>
Branch	tarea que devuelve el nombre de la tarea que sigue; las otras quedan en <code>skipped</code>
Short-circuit	tarea que, si devuelve <code>False</code> , saltea todo lo que depende de ella
XCom	mecanismo para pasar metadatos entre tareas. No datos
Variable	almacén clave-valor persistente, compartido entre corridas y DAGs
Dynamic Task Mapping (<code>.expand()</code>)	crea N instancias de una tarea en runtime, una por elemento de una lista
<code>map_index_template</code>	nombra cada instancia mapeada en la interfaz
<code>max_active_tasks</code>	cuántas tareas del DAG pueden correr a la vez

Término	Qué es
Trigger Rule	condición sobre el estado de las tareas de arriba para decidir si una tarea corre
Param	parámetro de corrida; genera un formulario en la interfaz
Idempotencia	correr una tarea dos veces deja el mismo resultado que correrla una
catchup=False	evita que Airflow ejecute las corridas atrasadas entre <code>start_date</code> y hoy
Scheduler	el proceso que decide cuándo lanzar cada tarea
dag-processor	el proceso que parsea la carpeta <code>dags/</code> cada pocos segundos

Documento generado a partir del código fuente del repositorio (`dags/dag_fichajes.py`, `include/fichajes/`) para servir de guía de estudio y explicación del proyecto.